Лабораторная работа №3 · Вариант B

Транспонирование и локальность памяти. Матрицы double, N_v = 3500; реализованы пять обязательных версий и две версии in-place.

Система: Apple M4, 10 ядер (4 P + 6 E), 16 ГБ, macOS 26.3.1; Apple Clang 17.0.0, LLVM libomp 23.1.2, **-O2**, C11. Справочные кеши M4 [1]: L1 данных P/E = 128/64 КиБ на ядро; L2 = 16/4 МиБ на кластер; отдельного CPU L3 нет.

Методика: omp_get_wtime(), один прогрев и 5 измерений, медиана; выделение, заполнение и проверка вне таймера. Все 180 запусков, включая прогрев, дали 0 несовпадений с rows. BW = $2N^2 \cdot 8 / (t \cdot 10^9)$ ГБ/с — эффективный, а не фактический трафик памяти.

1. Порядок обхода · 1 поток

N	rows, с	cols, с	BW rows, ГБ/с	BW cols, ГБ/с
256	0,000157	0,000040	6,68	26,18
512	0,000838	0,000359	5,00	11,68
1024	0,003710	0,001220	4,52	13,75
2048	0,019743	0,013501	3,40	4,97
3500	0,022800	0,060373	8,60	3,25

2. Размер блока · N = 3500, 1 поток, blocked

b	Время, с	BW, ГБ/с
4	0,008785	22,31
8	0,007081	27,68
16	0,009075	21,60
32	0,007686	25,50
64	0,008722	22,47
128	0,007920	24,75

3. Число потоков · N = 3500, b* = 8; S = T(rows, 1) / T_p

Потоки	rows_omp, с	S rows_omp	blocked_omp, с	S blocked_omp
1	0,020957	1,09	0,008138	2,80
2	0,011003	2,07	0,006184	3,69
4	0,006907	3,30	0,004363	5,23
8	0,005344	4,27	0,003947	5,78
16	0,005364	4,25	0,004028	5,66

4. False sharing · N = 3500, 8 потоков, rows_omp

Стратегия	Время, с	BW, ГБ/с
schedule(static)	0,005344	36,68
schedule(static, 1)	0,010144	19,32
schedule(static, 8)	0,006560	29,88

Дополнительно: in-place (1 поток) — 0,006105 с; in-place (8 потоков) — 0,002639 с; blocked_omp (8 потоков) — 0,003947 с. In-place меняет пары элементов одной матрицы; копия для повторов и эталон используются только стендом вне таймера.

Вывод

Разница обходов заметна уже при N = 256: rows читает подряд, но пишет с шагом N, а cols меняет роли чтения и записи. На N = 256–2048 быстрее cols, но при N = 3500 быстрее rows: результат зависит не только от объёма, но и от шага, конфликтов кеша и TLB. Лучший b* = 8: два блока занимают 1 КиБ и помещаются в L1, однако одной ёмкостью кеша этот оптимум объяснить нельзя. После 8 потоков время практически не улучшается; собственное ускорение blocked_omp от 1 до 8 потоков равно 2,06 раза, меньше примерно 4,02 раза для интеграла ЛР2, что согласуется с ограничением памяти. Ускорения blocked_omp в таблице 3 также включают выигрыш от изменения алгоритма относительно rows. static, 1 медленнее static в 1,90 раза: соседние столбцы B назначаются разным потокам, и запись в общие кеш-линии вызывает false sharing. Выдача строк порциями по 8 уменьшает этот эффект, но в данном запуске уступает непрерывным диапазонам static. Это объяснение согласуется с результатами; аппаратные счётчики промахов и когерентности не измерялись.

[1] Справочные параметры кешей: Eigen: измерения на Apple M4 (2026).